

Predicción de Churn de Clientes

De la predicción a la acción: usando IA para anticipar y prevenir la pérdida de clientes en e-commerce

Agenda

01

Contexto del Proyecto

Escenario de negocio y rol del analista

02

Planteamiento del Problema

El costo económico del churn

03

Dataset y Variables

5.630 clientes, 20 variables

04

Metodología de Trabajo

Entender → Delegar → Validar

05

Métricas y Evaluación

Más allá del accuracy

06

Cronograma y Entregables

4 semanas de trabajo

07

Impacto de Negocio

De la predicción a la acción ejecutiva

El Escenario de Negocio



La Empresa

Empresa de e-commerce con **5.630 clientes activos** que enfrenta una tasa de churn anual del **17%**. El gerente comercial necesita anticipar quiénes se irán antes de que dejen de comprar.



Tu Rol

No sos el programador. Sos el **responsable de negocio** que entiende el problema, dirige la solución con IA, interpreta los resultados y defiende cada decisión frente al gerente comercial.



La Pregunta Central

¿Podemos detectar qué clientes están por irse **antes** de que dejen de comprar? ¿Por qué nos dejan? La respuesta debe traducirse en **decisiones concretas** de retención.

💡 Enfoque de Negocios

No buscamos el modelo más preciso. Buscamos que entiendas:

- ✓ Qué resuelve el modelo
- ✓ Por qué funciona
- ✓ Qué limitaciones tiene
- ✓ Cómo explicárselo al gerente

💬 Mentalidad Clave

"Si no podés explicar por qué la IA hizo lo que hizo, no estás listo para la defensa."

Problema

El Costo del Churn

\$ Impacto Económico

Costo de adquisición vs. retención

5-25x

Churn anual en e-commerce

20-40%

Impacto en ganancias (5% retención)

25-95%

Adquirir un cliente nuevo cuesta **5 a 25 veces más** que retener uno existente.
Una mejora del 5% en retención puede aumentar las ganancias entre 25-95%.

⚠ El Problema con el Accuracy

Con un churn del 16%, un modelo que diga **"nadie se va"** obtiene 84% de accuracy. Suena bien, es **inútil**.

📈 Decisiones del Gerente Comercial

El objetivo no es solo predecir, sino **habilitar decisiones concretas** :



¿A quién intervenir?

Identificar clientes en riesgo 60-90 días antes



¿Con qué recursos?

Asignar presupuesto de retención eficientemente



¿Cuándo actuar?

Timing óptimo para intervenciones

Caso real: Empresas de telecomunicaciones usan gradient boosting para identificar clientes en riesgo 60-90 días antes de la cancelación, disparando ofertas de retención personalizadas.

Dataset: 5.630 Clientes, 20 Variables

Estructura del Dataset

Filas (clientes)	5.630
Columnas (variables)	20
ID	1
Target	1
Features	18

Desbalance de Clases



16% churn (Yes) vs. 84% retención (No)

Ojo: el accuracy es engañoso.

Variables Clave para el Análisis

-  **Tenure**
Meses como cliente. Clientes nuevos suelen tener mayor riesgo.
-  **SatisfactionScore**
Satisfacción 1-5. Hipótesis obvia — validar con datos.
-  **Complain**
¿Reclamó el último año? Alta señal, pero cuidado con leakage temporal.
-  **DaySinceLastOrder**
Días desde última compra. Inactividad puede indicar churn inminente.
-  **CashbackAmount**
Cashback recibido. ¿Los clientes con más beneficios se quedan?
-  **CityTier**
Nivel de ciudad (1-2-3). Útil para análisis de subgrupos.

Hipótesis de Negocio

5 hipótesis fundamentadas en lógica de negocio, validables con datos

H1 Tenure Bajo = Mayor Riesgo

Los clientes nuevos tienen mayor riesgo de churn. Aún no hay lealtad establecida ni costos de cambio percibidos. **Validación:** gráfico de tenure vs. tasa de churn + test estadístico.

H2 Quejas Aumentan Churn

Clientes que se quejaron (Complain=1) churnean más. **⚠ Cuidado:** leakage temporal. ¿Se quejaron antes o después de irse?

H3 Inactividad Predice Churn

Clientes con muchos días sin comprar (DaySinceLastOrder alto) están más cerca de irse. La inactividad es señal de desenganche.

H4 Baja Satisfacción = Churn

Clientes con menor SatisfactionScore tienen mayor probabilidad de churn. Es la hipótesis más intuitiva — pero debe validarse, no asumirse.

H5 Cashback No Garantiza Retención

El cashback no retiene si el cliente ya decidió irse. Hay que analizar si el beneficio se percibe antes o después de la decisión de churn.

☰ Método de Validación

Cada hipótesis requiere: **1 gráfico** que la muestre visualmente + **1 test estadístico** + interpretación en lenguaje de negocio.

Metodología de Trabajo

La IA es tu copiloto técnico, no tu reemplazante

01 Entender

Antes de pedirle algo a la IA, asegurate de entender **qué pregunta de negocio** estás respondiendo.

- ¿Qué decisión va a tomar el gerente con esto?
- ¿Por qué esta pregunta importa ahora?

Herramienta: Usá grill-me si tenés dudas sobre el concepto

02 Delegar

Le explicás el contexto a la IA, le pedís que proponga **2-3 alternativas** antes de ejecutar, y elegís la que tenga más sentido.

- Dale contexto de negocio, no solo instrucciones técnicas
- Exigí alternativas: "¿Y si hacemos esto otro?"

Herramienta: Cursor con IA integrada para ejecución

03 Validar

Revisá el output. No si el código corre — si **el resultado tiene sentido** de negocio. Documentá la decisión.

- ¿Tiene sentido para el problema que resolvemos?
- ¿Podría explicárselo al gerente sin tecnicismos?

Herramienta: decisions.md para registrar cada decisión

⚠ Antes de aceptar cualquier output de la IA, hacete estas tres preguntas:

- ¿Esto tiene sentido para el problema?
- ¿Podría explicárselo al gerente comercial?
- ¿Por qué esta opción y no otra?

Estrategia de Modelado

Del baseline al modelo potente, con validación rigurosa

Fases del Modelado

1 Modelo Baseline

El más simple posible. Si el complejo no le gana a tirar una moneda, algo salió mal.

2 Modelo Potente

Random Forest, Gradient Boosting. Métricas correctas, no accuracy.

Split Train/Test Estratificado

Proporción 80% / 20%

Método Estratificado

Reproducibilidad `random_state=42`

El split estratificado mantiene el 16% de churn en ambos subsets. Sin estratificación, train podría tener 18% y test 10% — **todo se contamina** .

Algoritmos Clave

Árbol de Decisión

Preguntas sí/no hasta clasificar. Es como un cuestionario: **fácil de leer y explicarle a un gerente** .

Random Forest

Cientos de árboles votando juntos. En vez de un médico, le preguntás a 500 y votan. Más robusto, menos overfitting.

Data Leakage

Algunas variables pueden estar **"espiando el futuro"** .

Ejemplo: Variable Complain — ¿se registró antes o después de que el cliente se fuera? Si es después, usarla es hacer trampa. **Documentá el riesgo en cada variable sospechosa.**

Métricas: Más Allá del Accuracy

Con clases desbalanceadas, el accuracy es engañoso. Estas son las métricas que importan.



Recall (Sensibilidad)

De los que se iban, ¿a cuántos detectaste?

Prioritaria cuando: el costo de perder un cliente supera el costo de intervenir innecesariamente.

"El radar del hospital: querés no perderte ningún caso"



Precision

De los que predijiste que se iban, ¿cuántos realmente se iban?

Importa cuando: los recursos de intervención son limitados (presupuesto, equipo).

"¿Cuántos de los que mandaste a tratamiento realmente lo necesitaban?"



F1-Score

Balance armónico entre precision y recall. Útil cuando necesitás equilibrar ambos objetivos.



AUC-ROC

Capacidad discriminativa general del modelo.

> 0.75

Decente

> 0.85

Excelente

SHAP Values

Cuánto aportó cada variable a cada predicción. **"El ticket del super: no solo el total, sino qué producto sumó cuánto."**

Cronograma: 3 Semanas

S1

Semana 1

05/06 — Setup y Entendimiento

- ✓ Configurar entorno: Cursor, GitHub, Python
- ✓ Instalar skills (grill-me, data-science-kit)
- ✓ Descargar dataset de Kaggle
- ✓ Responder: ¿Qué es churn? ¿Por qué importa?

Checkpoint: `df.head()` funciona, entorno activo, primer commit hecho

S2

Semana 2

12/06 — Exploración e Hipótesis

- ✓ EDA completo con ds-explorer
- ✓ Perfilado de datos completo
- ✓ 5 hipótesis de negocio en reports/01_hipotesis.md
- ✓ Validación con gráficos y tests estadísticos
- ✓ Split train/test estratificado

S3

Semana 3

19/06 — Modelado

- ✓ Modelo baseline (piso de comparación)
- ✓ Modelo potente (Random Forest, etc.)
- ✓ Métricas correctas (recall, precision, F1, AUC-ROC)
- ✓ decisions.md con registro de decisiones

S3

Semana 3

Entrega Final

- ✓ Reporte ejecutivo (PDF 4-6 páginas)
- ✓ Sin tecnicismos, para el gerente comercial
- ✓ Defensa oral de 15 minutos
- ✓ Defender cada decisión tomada

Principio: Cada semana construye sobre la anterior. No avanzás a la siguiente sin tener solida la actual.

Entregables y Evaluación

Cuatro Entregables Principales

01 EDA (Notebook + GitHub + Skills)

Código base definido en repositorio GitHub, entorno configurado con Cursor, skills instaladas. El notebook muestra `df.head()` y análisis exploratorio completo.

02 Modelado

Modelo baseline + modelo potente con métricas correctas. Demostrar que la herramienta funciona y que elegiste la métrica adecuada para el problema de negocio.

03 decisions.md

Registro de cada decisión importante: qué decidiste, por qué, alternativas descartadas, consecuencias. Es tu memoria del proyecto. En la defensa oral podés consultarlo.

04 Reporte Ejecutivo + Defensa Oral

PDF de 4-6 páginas sin tecnicismos para el gerente comercial + presentación oral de 15 minutos defendiendo cada decisión.

Dimensiones de Evaluación

La comunicación y el entendimiento valen más que la ejecución técnica.

Entendimiento del

Problema

¿Sabés qué pregunta estás respondiendo y con qué datos?

Alto

Análisis

Exploratorio

¿Tus hipótesis tienen lógica de negocio? ¿Las validaste?

Alto

Modelado y Métricas

¿Elegiste bien la métrica? ¿Sabés por qué ese modelo?

Medio

Comunicación y

Defensa

¿Podés explicárselo a un gerente? ¿Defendés cada decisión?

Alto

Conclusión

De la Predicción a la Acción

El verdadero valor no está en el modelo, sino en las **decisiones que habilita** .



Identificar

Clientes en riesgo 60-90 días antes
de que se vayan



Asignar

Recursos de retención de forma
eficiente y medible



Medir

ROI de las intervenciones y iterar

"La IA es herramienta, no oráculo. La diferencia entre un buen proyecto y uno excelente está en **saber explicar por qué se tomó cada decisión** ."

