

Predicción de Churn de Clientes — Reporte Ejecutivo

Para: Gerencia Comercial **Materia:** Inteligencia Artificial Aplicada a Negocios — 1er Cuatrimestre 2026 **Dataset:** 5.630 clientes de e-commerce, 20 variables

1. El problema en una página

De nuestros **5.630 clientes**, **948 (16,8%) dejaron de comprar**. Adquirir un cliente nuevo cuesta entre 5 y 25 veces más que retener uno existente: cada punto de churn que recuperamos va directo a la rentabilidad.

La pregunta que respondimos: **¿podemos saber quién está por irse antes de que se vaya, y por qué?**

La respuesta es sí. Construimos un sistema que, probado sobre 1.126 clientes que nunca había visto, **detectó a 183 de los 190 que efectivamente se fueron (96%)**, con solo 12 falsas alarmas. Esto significa que el equipo comercial puede trabajar con una lista corta y confiable de clientes en riesgo, en lugar de hacer campañas masivas a ciegas.

Las tres conclusiones más importantes para el negocio:

- 1. **El churn es un problema de los primeros 30 días.** Más de la mitad de los clientes con un mes o menos de antigüedad se va. Pasado el año, casi nadie se va.
- 2. **La encuesta de satisfacción no sirve para anticipar el churn** — los datos muestran lo contrario de lo esperado: los que puntúan 5 se van *más* que los que puntúan 1.
- 3. **Quien reclama se va casi 3 veces más.** Cada reclamo sin resolver es una alerta roja accionable.

2. Qué encontramos en los datos (5 hipótesis puestas a prueba)

Antes de construir el modelo planteamos 5 hipótesis de negocio y las validamos con los datos. Dos resultaron **falsas**, y eso vale más que las confirmadas: nos evita gastar plata en acciones que no funcionan.

✅ **H1 — Los clientes nuevos se van mucho más (CONFIRMADA)**

Antigüedad	Tasa de churn
0–1 mes	51,8%
2–6 meses	8,0%
7–12 meses	5,7%
13–24 meses	6,5%
Más de 2 años	0,0%

La mitad de los clientes nuevos se va en el primer mes; ningún cliente con más de 2 años se fue. La antigüedad mediana de los que se van es 1 mes, contra 10 meses de los que se quedan (diferencia estadísticamente contundente, $p < 0,001$).

Decisión que habilita: el presupuesto de retención rinde más invertido en *onboarding* (primeros 30–60 días) que repartido en toda la base.

✔ H2 — Quien reclama se va casi 3 veces más (CONFIRMADA, con una advertencia)

Churn entre quienes reclamaron: 31,7%. Entre quienes no: 10,9%.

Advertencia metodológica: no sabemos si el reclamo se registró antes o después de la decisión de irse. Verificamos que el modelo funciona casi igual de bien sin esta variable, así que la conclusión de negocio se sostiene: **un reclamo es una alerta temprana que merece respuesta inmediata.**

✗ H3 — "La inactividad anticipa el churn" (REFUTADA)

Esperábamos que los clientes con más días sin comprar estuvieran más cerca de irse. Los datos muestran lo contrario: los que se fueron habían comprado **más recientemente** (mediana 2 días vs. 4 días).

Lectura de negocio: muchos clientes hacen una última compra, tienen una mala experiencia y se van enseguida. La señal de riesgo no es el silencio: es **lo que pasa inmediatamente después de una compra** (demora, producto defectuoso, mala atención). La ventana para retener es corta y empieza el día de la compra.

✗ H4 — "Baja satisfacción = más churn" (REFUTADA)

La hipótesis más intuitiva resultó falsa:

Score de satisfacción	Tasa de churn
1 (peor)	11,5%
3	17,2%
5 (mejor)	23,8%

Los clientes que puntúan 5 se van **más del doble** que los que puntúan 1. Posibles explicaciones: la encuesta mide la satisfacción con una compra puntual y no la lealtad; o los clientes ya decididos a irse responden por compromiso.

Decisión que habilita: no usar la encuesta de satisfacción como tablero de retención. Hoy nos estaría dando una falsa sensación de seguridad exactamente con los clientes que están por irse.

⚠ H5 — El cashback acompaña la retención, pero no es la causa (MATIZADA)

Los que se quedan reciben más cashback (mediana \$166 vs. \$150). Pero el cashback crece con la antigüedad, y la antigüedad es el verdadero factor protector: la correlación no prueba que regalar cashback retenga. **Recomendación:** probarlo con un experimento controlado (a un grupo de riesgo se le da cashback extra, a otro no, y se compara) antes de invertir.

3. El sistema de predicción

Trabajamos en dos etapas, comparando siempre contra un piso:

Modelo	¿Detecta a los que se van? (Recall)	¿Cuántas alarmas son reales? (Precision)	Calidad global (AUC)
Piso: "nadie se va"	0%	—	0,50
Modelo simple (Regresión Logística)	85%	44%	0,89
Modelo final (Random Forest)	96%	94%	0,99

Tres aclaraciones en lenguaje claro:

- **Por qué no usamos "accuracy":** como el 83% de los clientes se queda, un modelo inútil que diga "nadie se va" acierta el 83% de las veces. Por eso medimos *de los que se iban, a cuántos detectamos* (recall) y *de los que señalamos, cuántos eran reales* (precision).
- **Por qué priorizamos recall:** perder un cliente cuesta mucho más que llamar de más a uno que no se iba. Preferimos alguna falsa alarma antes que dejar pasar un cliente en riesgo.
- **Qué es el Random Forest:** cientos de "cuestionarios de preguntas sí/no" sobre el cliente que votan en conjunto. Es como consultar a 300 analistas en vez de a uno.

Qué variables pesan más en la predicción: la antigüedad explica por lejos la mayor parte (25% de la importancia), seguida por el cashback recibido, los reclamos, la distancia del depósito al domicilio y los días desde la última compra.

Honestidad sobre los resultados: un acierto del 96–99% en datos históricos es excelente, pero en el mundo real va a ser menor. El dataset es una foto de un momento; recomendamos un piloto controlado antes de confiar el presupuesto entero al modelo (ver sección 5).

4. De la predicción a la acción

Acción	A quién	Por qué (evidencia)
Programa de onboarding intensivo (seguimiento activo los primeros 60 días)	Clientes con < 2 meses	H1: 51,8% de churn en el primer mes
Protocolo de reclamo = alerta roja (respuesta < 24 hs + compensación)	Cualquier cliente que reclama	H2: el reclamo casi triplica el churn
Encuesta post-compra inmediata sobre la experiencia de entrega	Compradores recientes	H3: el churn ocurre justo después de una compra
Lista semanal de riesgo generada por el modelo	Top de probabilidad de churn	El modelo detecta 96 de cada 100 que se van
Experimento A/B de cashback antes de escalar el beneficio	Muestra del grupo de riesgo	H5: la correlación no prueba causalidad

Cuánto está en juego (estimación conservadora): si el ticket anual promedio de un cliente es \$X, los 948 clientes perdidos representan \$948·X de facturación anual. Reteniendo solo al 20% de los que el modelo detecta, se recuperan ~180 clientes por ciclo. La bibliografía indica que mejorar 5 puntos la retención puede aumentar las ganancias entre 25% y 95%.

5. Limitaciones y próximos pasos

Limitaciones que asumimos abiertamente: 1. **Foto, no película:** el dataset no tiene fechas; no podemos garantizar que todas las variables se midieron antes del churn (riesgo de "leakage"). Lo mitigamos verificando el modelo sin la variable más sospechosa (reclamos) — sigue funcionando. 2. **Datos faltantes:** un tercio de los clientes tiene algún dato incompleto; los completamos con valores típicos (medianas). 3. **Resultados sobre datos históricos:** el rendimiento real se confirma recién en producción.

Próximos pasos propuestos: 1. Piloto de 1 ciclo comercial: el modelo genera la lista de riesgo, el equipo interviene a la mitad (grupo de tratamiento) y a la otra mitad no (control). Se mide el ROI real de la retención. 2. Incorporar fechas a la captura de datos para eliminar el riesgo de leakage. 3. Revisar la encuesta de satisfacción (H4 sugiere que hoy no mide lo que creemos).

Las decisiones técnicas, alternativas evaluadas y descartadas están documentadas en `decisions.md`. Los gráficos de cada hipótesis están en `reports/figuras/`.